Parcours de formation DATA

De la donnée à la valeur

INÈS KAMOUN FOURATI

global knowledge™



global knowledge

CADRE DE LA FORMATION

Cinq consignes à respecter chaque jour

- **Signer l'émargement** matin et après-midi, pour chaque jour de formation.
- **Remplir le formulaire de satisfaction** à la fin de chaque formation.
- **Garder le silence** autour de vous pendant les sessions.
- **Garder votre caméra activée** tout au long de la journée.
- **Ne pas hésiter à poser vos questions** à tout moment.

global knowledge

PROJET FIL ROUGE

Du transactionnel au datawarehouse

Sprint 1 — Jour 7 : de la source à la couche Gold

Contexte métier

L'activité d'une boutique en ligne de prêt-à-porter (Femme, Homme, Enfant) est étudiée.

Douze mois de transactions sont couverts : du 01/09/2024 au 31/08/2025.

Les données sont produites par le site marchand et stockées dans une base transactionnelle PostgreSQL.

Un pilotage de l'activité est attendu par la direction : les ventes, les produits, les clients, la logistique et les retours doivent être suivis.

Un datawarehouse fiable doit être conçu et alimenté, puis exploité dans Power BI.

Objectifs du projet

01 Les données sources sont ingérées sans altération (Bronze).

02 Les données sont nettoyées, typées et contrôlées (Silver).

03 Un modèle analytique est conçu pour répondre aux besoins métier (Gold).

04 La chaîne complète est orchestrée et rendue rejouable.

05 Les performances des requêtes sont analysées et optimisées.

06 Un tableau de bord sécurisé est publié (Sprint 2 — J8).

La base source : boutique_pret_a_porter

Table	Volume	Contenu
clients	8 000	Référentiel des clients
produits	500	Catalogue de prêt-à-porter
commandes	50 000	En-têtes de commande
lignes_commande	≈ 111 000	Détail des articles commandés
retours	6 000	Retours et remboursements

La base est fournie sous forme de script SQL et de 5 fichiers CSV. Le dictionnaire de données est fourni dans le document boutique_pret_a_porter_description.docx.

global knowledge.

Architecture cible

Sources PostgreSQL + CSV

BRONZE

Brut, tel que reçu

Schéma PostgreSQL : bronze

SILVER

Nettoyé, contrôlé

Schéma PostgreSQL : silver

GOLD

Modèle analytique

Schéma PostgreSQL : gold

Power BI

Restitution (J8)

Flux : Sources → BRONZE → SILVER → GOLD → Power BI

Orchestration Airflow entre les couches · tests dbt

Stack technique

Besoin	Outil
Stockage	PostgreSQL
Ingestion	Python (pandas, SQLAlchemy)
Transformation	dbt
Qualité des données	Tests dbt
Orchestration	Apache Airflow
Restitution (J8)	Power BI

Les outils vus lors des jours 1 à 6 sont réutilisés ; aucun nouvel outil n'est introduit.

Organisation des deux sprints

Sprint	Jour	Périmètre	Livrable principal
Sprint 1	J7	Bronze → Silver → Gold, orchestration, optimisation	Pipeline complet et documenté
Sprint 2	J8	Power BI, sécurité, publication, soutenance	Tableau de bord publié + soutenance

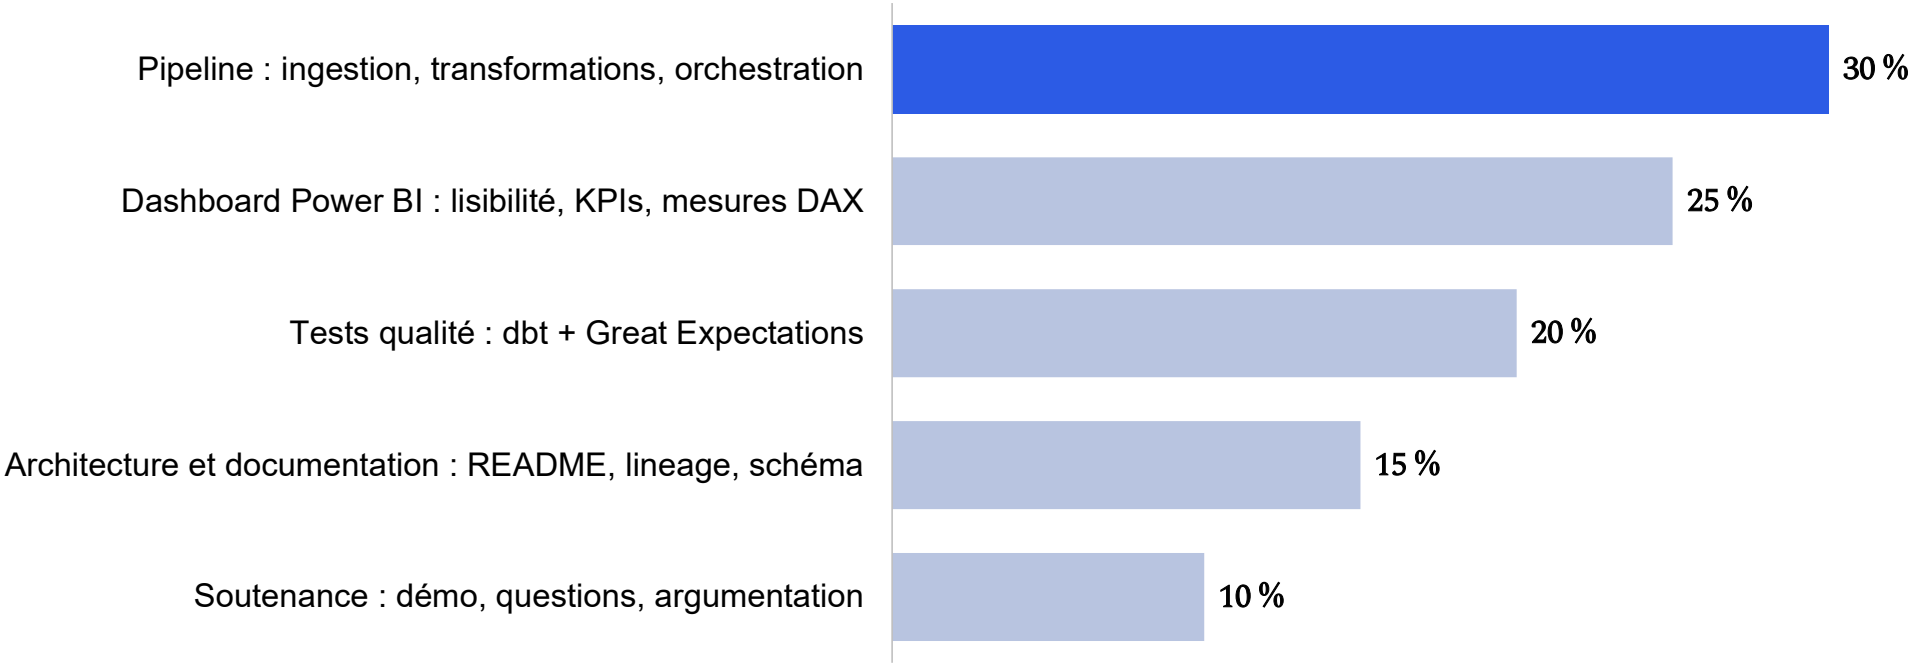
- Point d'avancement en fin de matinée et en fin de journée.
- Livrables déposés sur le dépôt du projet avant chaque échéance.

ÉVALUATION

Grille d'évaluation de l'atelier

Le jury note l'atelier fil rouge CGI DataViz sur cinq critères ; le pipeline pèse le plus.

Pondération par critère, soutenance J8



Source : Parcours Data Engineering & Analytics, Cours 6, grille d'évaluation

JOUR 7

Sprint 1

Tâches et livrables

global knowledge

BLOC 1 · 1H30

Ingestion Bronze

Objectif

Copier les données sources dans le schéma bronze sans transformation.

Tâches

- Créer le schéma bronze.
- Charger les 5 tables sources par un script Python paramétrable.
- Ajouter la date de chargement et la source.
- Comparer automatiquement les volumétries source et cible.

Livrables et critère

- Script d'ingestion livré.
- Journal de chargement produit.

Critère : volumes Bronze strictement égaux aux volumes source.

BLOC 2 · 2H

Couche Silver et qualité

Objectif

Produire des données propres, typées et fiables dans silver.

Tâches

- Profiler Bronze : valeurs manquantes, doublons, incohérences et formats.
- Définir et documenter les règles de nettoyage.
- Développer les modèles Silver avec dbt.

Livrables

- Rapport de profilage.
- Modèles dbt.

BLOC 2 · QUALITÉ

Points d'attention

- Les anomalies présentes dans la source ne sont pas listées : leur détection fait partie de l'évaluation.
- Chaque règle de nettoyage doit être justifiée.
- Conserver les lignes rejetées dans une table de quarantaine plutôt que les supprimer.
- Vérifier par des tests les règles de gestion décrites dans le dictionnaire de données.

BLOC 3 · 1H30

Couche Gold

Objectif

Concevoir et alimenter un modèle analytique dans gold.

Besoins métier

- Suivre l'évolution du chiffre d'affaires et de la marge.
- Analyser la performance des produits : ventes, marge, retours.
- Mesurer le comportement et la fidélité des clients.
- Évaluer la qualité logistique : délais de livraison.
- Mesurer l'efficacité des promotions et des soldes.

Livrables

- Schéma du modèle Gold présenté et justifié.
- Modèles dbt Gold.
- Requêtes de contrôle des indicateurs clés.

BLOC 4 · 1H

Orchestration

Objectif

Exécuter la chaîne de bout en bout par Airflow.

Tâches

1. Construire un DAG unique : ingestion Bronze → dbt Silver → tests qualité → dbt Gold.
2. Arrêter le pipeline en cas d'échec d'un test bloquant.
3. Rendre le pipeline idempotent.
4. Archiver les rapports qualité à chaque exécution.

Livrables

- Code du DAG.
- Capture d'une exécution réussie.

global knowledge

BLOC 5 · 1H

Optimisation des performances

Objectif

Identifier et optimiser les requêtes les plus coûteuses.

Tâches

- Sélectionner trois requêtes analytiques représentatives.
- Analyser leurs plans avec EXPLAIN ANALYZE.
- Concevoir et créer les index pertinents (aucun index n'est fourni).
- Comparer les temps avant et après optimisation.

Livrables

- Script de création des index.
- Benchmark avant / après avec justification de chaque index.

CRITÈRES DE FIN

Definition of Done

Une tâche est terminée lorsque :

- Le code est versionné et exécutable depuis un environnement vierge.
- Les tests associés sont exécutés sans échec.
- Les choix techniques sont documentés dans le README.
- Les résultats sont vérifiés par une requête de contrôle.
- Aucune donnée n'est modifiée dans la base source.

Conventions de travail

Schémas et modèles

- Schémas : bronze, silver, gold (+ quarantaine si nécessaire).
- Définir un préfixe par couche et l'appliquer de façon homogène aux modèles.

Code et collaboration

- Nommage SQL : snake_case pour les tables et colonnes.
- Documentation : consigner au fil de l'eau les règles de nettoyage et les choix de modélisation.

SPRINT 1 · JOUR 7

Place à la réalisation

Les questions peuvent être posées à tout moment.

global knowledge

PROJET FIL ROUGE

Du datawarehouse au tableau de bord

Sprint 2 — Jour 8 : de la couche Gold à la soutenance

RAPPEL

Point de départ : les acquis du Sprint 1

Bronze

Les 5 tables sources sont chargées sans altération.

Silver

Les données sont nettoyées et testées ; les rejets sont isolés en quarantaine.

Gold

Le modèle analytique est alimenté et contrôlé par des requêtes de référence.

Orchestration

La chaîne est exécutée de bout en bout par le DAG Airflow.

Si le Sprint 1 n'a pas été achevé, la couche Gold doit être finalisée en priorité. Un schéma gold de référence peut être fourni afin que le Sprint 2 ne soit pas bloqué.

global knowledge

PÉRIMÈTRE

Le Sprint 2 dans l'architecture



Sprint 1 · J7

Sprint 2 · J8

Modèle sémantique et DAX

Les tables Gold sont exploitées et les indicateurs métier sont calculés.

Rapport

Un tableau de bord orienté décision est conçu pour la direction.

Sécurité et publication

L'accès est restreint par région et le rapport est publié.

Les méthodes et outils du Jour 6 sont réutilisés ; aucun nouvel outil n'est introduit.

BLOC 1 · 30 MIN

Modèle sémantique Power BI

Objectif

Un modèle sémantique fiable est construit dans Power BI à partir du schéma gold.

Livrables

- Projet Power BI (format .pbix recommandé).
- Capture commentée de la vue Modèle.

Critère : les volumes chargés sont strictement égaux aux volumes Gold.

Tâches

1. La connexion au schéma gold est établie ; le mode de stockage est justifié.
2. Les relations sont créées et vérifiées : cardinalité, sens de filtrage.
3. Une table de dates est ajoutée et marquée comme table de dates.
4. Les colonnes techniques sont masquées ; les formats sont définis.

global knowledge

BLOC 2 · 1H

Mesures DAX métier

Objectif

Les indicateurs attendus par la direction sont calculés par des mesures DAX documentées.

Livrables

- Mesures décrites dans Power BI (propriété Description).
- Tableau de rapprochement DAX / SQL.

Critère : aucun écart DAX / SQL n'est laissé inexpliqué.

Tâches

1. Une table de mesures dédiée est créée.
2. Le socle de mesures obligatoires est développé (diapositive suivante).
3. Une mesure de cumul de l'exercice est ajoutée (fin d'exercice au 31/08).
4. Chaque mesure est rapprochée d'une requête de contrôle SQL du Jour 7.

BLOC 2 · RÉFÉRENTIEL

Mesures attendues par besoin métier

Besoin métier	Socle obligatoire	Complément (si le temps le permet)
Chiffre d'affaires et marge	CA, Marge brute, Taux de marge, CA cumulé de l'exercice	CA mois précédent, Évolution mensuelle
Performance des produits	Quantités vendues, Taux de retour	Rang du produit (RANKX)
Comportement et fidélité clients	Clients actifs, Panier moyen	Taux de réachat, Part des nouveaux clients
Qualité logistique	Délai moyen de livraison	Part des commandes livrées hors délai
Promotions et soldes	CA avec code promo	Remise moyenne, Part du CA en soldes

Le socle obligatoire est attendu en fin de bloc ; les compléments sont valorisés lors de la soutenance.

BLOC 2 · QUALITÉ

Points d'attention

! L'exercice commence le 1er septembre : la fin d'exercice (31/08) doit être paramétrée dans les fonctions de cumul.

! Le traitement des commandes annulées et des retours doit être défini, justifié et appliqué de façon homogène.

! Les mesures sont privilégiées aux colonnes calculées lorsque le résultat dépend du contexte de filtre.

! Les écarts entre DAX et SQL doivent être expliqués et documentés, jamais masqués.

global knowledge

BLOC 3 · 1H

Conception du rapport

Objectif

Un rapport lisible et orienté décision est conçu pour la direction.

Livrables

- Rapport de 2 pages dans le projet Power BI.

Critère : chaque page répond à une question métier explicite.

Tâches

1. Une maquette rapide des deux pages est esquissée.
2. Un thème cohérent est appliqué aux deux pages.
3. Les visuels et les segments sont choisis selon la question métier traitée.
4. L'accessibilité est vérifiée : contraste et texte de remplacement.

global knowledge

BLOC 3 · STRUCTURE

Pages attendues du rapport

01

Synthèse direction

Les KPI clés et leur évolution mensuelle sont présentés.

02

Produits

Les ventes, marges et retours sont analysés par catégorie, collection et marque.

02

Clients

Le comportement d'achat, la fidélité et les canaux d'acquisition sont étudiés.

02

Logistique et promotions

Les délais de livraison, les retours et l'effet des promotions sont suivis.

La page Synthèse est obligatoire ; une seconde page d'analyse est choisie parmi les trois thèmes proposés.

global knowledge

BLOC 4 · 30 MIN

Sécurité RLS et publication

Objectif

Le rapport est sécurisé par région puis publié dans le service Power BI.

Livrables

- Captures des tests RLS (Desktop et service).
- Lien du rapport publié.

Critère : seules les données de sa région sont visibles par chaque responsable.

Tâches

1. Une table des responsables régionaux est ajoutée ; un rôle dynamique est défini avec USERPRINCIPALNAME().
2. Le rôle est testé dans Desktop (« Afficher en tant que »).
3. Le rapport est publié dans l'espace de travail de la formation.
4. Les membres sont affectés au rôle ; la sécurité est vérifiée dans le service.

global knowledge

BLOC 5 · 13H45 – 17H30

Soutenances individuelles

30 min

par apprenant

- 20 min de présentation et de démonstration
- 10 min de questions et de retour

Sept passages sont organisés, pause de 15 min incluse.

Contenu attendu

1. L'architecture et les choix techniques sont présentés.
2. Les anomalies détectées et les règles de nettoyage sont justifiées.
3. Le modèle Gold et les mesures clés sont expliqués.
4. Le tableau de bord est démontré en direct, sécurité comprise.
5. Les difficultés rencontrées et les pistes d'amélioration sont exposées.

global knowledge

CRITÈRES DE FIN

Definition of Done — Sprint 2

Une tâche est considérée comme terminée lorsque :

- ✓ Le projet Power BI est versionné et s'actualise sans erreur.
- ✓ Chaque mesure est rapprochée d'une requête de contrôle SQL.
- ✓ Les choix de modélisation et de visualisation sont documentés dans le README.
- ✓ La sécurité RLS est vérifiée dans Desktop et dans le service.
- ✓ Aucune donnée n'est modifiée dans les couches Bronze, Silver et Gold.

SPRINT 2 · JOUR 8

Place à la réalisation

Les questions peuvent être posées à tout moment.